

Yıldız Teknik Üniversitesi
Elektrik-Elektronik Fakültesi
Bilgisayar Mühendisliği Bölümü

BLM 3510 Yapay Zeka 2025/2
Proje Ödevi

Prof. Dr. Mehmet Fatih Amasyalı

1 - Veri Üretimi

Verilen beş problem için veriler C dilinde kodlanan program ile üretilmiştir. 25x25'lik binary matrisler ve çıktı değerleri, problemlere özgü olarak oluşturulup sonrasında CSV dosyası olarak kaydedilmiştir.

Bu verilerin oluşturulma yöntemleri şu şekildedir:

1.1 - Problem A ve B

- Belirlenen veri adeti ve matris boyutu ile 25x25 binary matris dizisi oluşturulur.
- Her bir matris için 5 adet nokta rastgele konumlarda olacak ve aynı konuma tekrar nokta ataması yapılmayacak şekilde yerleştirilir.
- En yakın ve en uzak nokta çiftleri arasındaki Manhattan mesafesi hesaplanılarak kaydedilir.
- Matris boyutu için Manhattan mesafesi aralıkları belirlenir. (Örneğin 25x25'lik matris için 0-50 aralığı)
- Bu aralığa göre verilerin dağılım sıklığı hesaplanır.
- Belirtilen minimum normalizasyon değeri ile veriler normalize edilerek aralıkların veri sayısı eşitlenir.
- Veriler CSV dosyasına, {matris, çıktı} satır çifti olarak kaydedilir.

Bu iki problem için 10 milyon adet veri rastgele biçimde oluşturulmuştur. Veriler incelendiğinde her bir aralık için yeterli veri üretiminin imkansız olduğu gözlemlenmiştir. Bazı uç değerlerin oluşması milyonda bir gibi düşük ihtimallere sahip olduğundan o aralıklar için yeterli veri oluşturulamadı.

Örneğin, Problem A için teorik maksimum Manhattan mesafesi 24 olmasına rağmen pratikte en fazla 21 çıktısı gözlemlendi (1 örnek). Bu sebeple verilerin normalize edilip aralıkların eşitlenmesi için filtreleme yapılmıştır.

Problem A, 1-17 değer aralığına filtrelenmiştir. Her bir aralık için 200 örnek, toplamda ise 3400 örnek oluşturulmuştur.

Problem B, 7-48 değer aralığına filtrelenmiştir. Her bir aralık için 200 örnek, toplamda ise 8400 örnek oluşturulmuştur.

1.2 - Problem C, D ve E

Veri üretimi için aynı yöntemler uygulandı. Bu problemler için filtreleme yapılmasına ihtiyaç duyulmadan tüm aralıklar için veri oluşturulabildi.

Problem C için 1-10 değer aralığında her bir aralık için 500 örnek, toplamda ise 5000 örnek oluşturulmuştur.

Problem D için 0-1 değer aralığında her bir aralık için 1000 örnek, toplamda ise 2000 örnek oluşturulmuştur.

Problem E için 1-48 değer aralığında her bir aralık için 200 örnek, toplamda ise 9600 örnek oluşturulmuştur.


Problem tiplerine uygun olarak Problem A, B ve E için Regresyon, Problem C ve D için ise Sınıflandırma kullanılacaktır.

Veri Setleri Özet Tablosu:


Veri Setleri Özet Tablosu

Problem	Dosya	Toplam Örnek	Nokta Sayısı	Çıktı Aralığı	Her Değerden Örnek	Problem Tipi
A	a_200.csv	3400	5 (sabit)	1-17	200	Regresyon (Min Manhattan)
B	b_200.csv	8400	5 (sabit)	7-48	200	Regresyon (Max Manhattan)
C	c_500.csv	5000	1-10	1-10	500	Sınıflandırma (Nokta sayısı)
D	d_1000.csv	2000	1-10	0-1	1000	Binary (Tek/Çift)
E	e_200.csv	9600	1-10	1-48	200	Regresyon (Köşe mesafesi)


Normalizasyon sonrası çıktı dağılımları:




Problem A için örnek matrisler:




Problem B için örnek matrisler:




Problem C için örnek matrisler:



Problem D için örnek matrisler:



Problem E için örnek matrisler:



1.3 - Eğitim / Test Verisi Dağılımı

Veri kümeleri %80 / %20 oranında eğitim ve test olarak ayrılmıştır. Test için ayrı veri üretilmemiştir. Çeyrek, yarım ve tam eğitimler de bu veriler üzerinden yapılacaktır.

Eğitim / Test Veri Bölümü

Problem	Toplam	Eğitim	Test	Çeyrek Eğitim	Yarım Eğitim	Tam Eğitim
A	3400	2720 (80%)	680 (20%)	680 (25%)	1360 (50%)	2720 (100%)
B	8400	6720 (80%)	1680 (20%)	1680 (25%)	3360 (50%)	6720 (100%)
C	5000	4000 (80%)	1000 (20%)	1000 (25%)	2000 (50%)	4000 (100%)
D	2000	1600 (80%)	400 (20%)	400 (25%)	800 (50%)	1600 (100%)
E	9600	7680 (80%)	1920 (20%)	1920 (25%)	3840 (50%)	7680 (100%)

2 - YSA Modeli

2.1 - Model Seçimi

Giriş verisi 2 boyutlu bir matris olduğundan dolayı bu yapıya daha uygun olacağı düşünüldüğünden CNN mimarisi tercih edilmiştir. Tüm problemler için bu mimari kullanılacaktır. Yalnızca çıkış katmanı problem tipine göre değiştirilmiştir.

2.2 - Model Mimarisi

CNN modeli, 2 konvolüsyon bloğu ve 2 tam bağlantılı katmandan oluşmaktadır.

Katman	Açıklama
Girdi	2 boyutlu matris
Conv2D	İlk özellik çıkarım katmanı
MaxPool2D	Uzamsal boyut azaltma
Conv2D	İkinci özellik çıkarım katmanı
MaxPool2D	Uzamsal boyut azaltma
Flatten	Düzleştirme
Linear + ReLU	Tam bağlantılı katman
Linear	Tahmin katmanı

2.3 - Çıkış Katmanı

Problem A, B ve E için Regresyon, Problem C ve D için Sınıflandırma kullanılmıştır.

Problem	Çıkış	Kayıp Fonksiyonu
A, B, E	1 nöron (Regresyon)	MSELoss
C	10 nöron (Sınıflandırma)	CrossEntropyLoss
D	1 nöron (Binary Sınıflandırma)	BCEWithLogitsLoss

3 - Hiperparametre Optimizasyonu

3.1 - Yöntem

Hiperparametre optimizasyonu için Grid Search yöntemi kullanılmıştır. Eğitim verisi kendi içinde %80 eğitim ve %20 test olarak bölünmüştür. Her kombinasyon için 25 epoch eğitilmiş ve doğrulama setindeki performansına göre her bir problem için en iyi kombinasyon seçilmiştir.

3.2 - Arama Uzayı

Parametre	Değerler	Açıklama
Learning Rate	0.001, 0.0005, 0.0001	Öğrenme hızı
Batch Size	32, 64	Mini batch boyutu
Conv filters (f1, f2)	(32, 64), (64, 128)	Konvolüsyon katmanı filtre sayıları
FC size (fc)	128, 256	Tam bağlantılı katman nöron sayısı

Toplam 8 konfigürasyon her problem için denenmiştir.

3.3 - Seçim Kriterleri

- Regresyon problemleri (A, B, E) = En düşük MAE değeri
- Sınıflandırma Problemleri (C, D) = En yüksek doğruluk değeri

3.4 - Eğitim Ayarları

Parametre	Arama Aşaması	Eğitim Aşaması
Epoch	20	150
Early Stopping Patience	10	20
Optimizer	Adam	Adam

Aşırı öğrenmeyi (overfitting) engellemek için eğitimi erken bitirme kullanılmıştır. Eğitim verisinin %10'u doğrulama amaçlı kullanılmıştır.

3.5 - Sonular

Her problem iin seilen en iyi hiperparametre kombinasyonları:

Problem	Learning Rate	Batch Size	Conv Filters	FC Size
A	0.001	32	(64, 128)	256
B	0.0001	32	(32, 64)	256
C	0.001	64	(64, 128)	128
D	0.0001	64	(64, 128)	128
E	0.001	32	(32, 64)	128

4 - Sonular


4.1 - Problem A

Problem A iin farklı eėitim kmesi oranları ile sonular aaėıdaki gibidir:

Eėitim Kmesi Oranı	Eėitim Veri Adeti	Epoch	MAE	RMSE	R ²
%25	612	38	2.360	2.934	0.641
%50	1224	54	1.752	2.197	0.799
%100	2448	84	1.414	1.772	0.869


Sonular incelendiėinde modelin en yakın Manhattan mesafesi problemini kabul edilebilir dzeyde ėrenebildiėi gzlemlenmiřtir. Eėitim verisi arttıka tahmin performansı tutarlı řekilde iyileřmiřtir.

Problem A: Min Manhattan (5 nokta)
Veri Boyutunun Etkisi





Eğitim eğrisi incelendiğinde, eğitim verisi ve epoch sayısı arttıkça modelin performansının tutarlı şekilde iyileştiği gözlemlenmiştir. Fakat %25 ve %50 eğitim kümeleri için overfitting oluşmuştur. Loss %100 eğitim kümesi ile benzer olmasına rağmen MAE belirli yerlerde takılmıştır.

Problem A: Min Manhattan (5 nokta) — Eğitim Süreçleri




Problem A için, 1-17 değer aralığındaki sonuçlar ayrı ayrı incelendiğinde modelin genel olarak dengeli bir sonuç gösterdiği söylenebilir.

Model en yüksek performansı ise 1-2 değer aralığında göstermiştir. Bunun sebebi CNN mimarisinde yakın nokta çiftlerinin tek filtre ile yakalanabilmesi yani güçlü lokal ilişki bulunmasıdır. Aynı sonuç 3 değer aralığında gözlemlenemedi çünkü 2 boyutlu matris düşünüldüğünde mesafe 1 ve 2 için çok az sayıda düzen, yerleşme ihtimali bulunmaktadır. Ancak 3+ değerler için daha fazla konfigürasyon bulunur. Bu sebeple varyans artar, tahmin zorlaşır.



Problem A için modelin yaptığı hatalar incelendiğinde, bazı durumlarda modelin ortalamaya yakın tahmin yapma eğiliminde olduğu gözlemlenmiştir. Model, genel nokta dağılımına bakarak tahmin üretmekte, yerel yakın çiftleri ayırt etmekte zorlanmaktadır.

Özellikle noktaların matris genelinde dağınık konumlandığı ve en yakın çiftin yüksek mesafede olduğu durumlarda (örn. mesafe=15) model, geometrik karmaşıklık nedeniyle yeterli tahmin başarısı sağlayamamıştır.



4.2 - Problem B



Problem B için farklı eğitim kümesi oranları ile sonuçlar aşağıdaki gibidir:

Eğitim Kümesi Oranı	Eğitim Veri Adeti	Epoch	MAE	RMSE	R ²
%25	1512	75	2.431	3.124	0.934
%50	3024	74	1.890	2.404	0.961
%100	6048	60	1.648	2.118	0.969

Model, Problem B için ortalama bir performans göstermiştir. Maksimum Manhattan mesafesi, en uzak iki noktanın konumlarına bağlı olduğundan CNN bu noktaların matris üzerindeki genel konumlarını iyi bir şekilde öğrenebilmiştir. Problem A'daki Minimum mesafe problemine göre daha kolaydır çünkü modelin tüm nokta çiftlerini karşılaştırması gerekmez, yalnızca en uçtaki noktaları tespit etmesi yeterlidir.



Problem A'ya benzer şekilde veri miktarı arttıkça öğrenme başarısı ve doğruluk oranı da artmıştır.

Çıktı değer aralığı Problem A'ya göre daha geniş olduğundan R^2 varyans değerinin daha yüksek olduğu gözlemlendi.




Dağılım grafiği incelendiğinde Problem A'ya kıyasla çok daha dengeli bir dağılım gözlemlendi.

Bu problemin yapısı gereği tüm değer aralıklarının CNN için benzer zorlukta olmasından dolayı bu sonuçların normal olduğu söylenebilir.



Problem B için kötü sonuçlar incelendiğinde Problem A'ya benzer şekilde model bazı yakın yerel noktaların bulunduğu durumlarda hatalı tahminler yapmıştır. (Örnek 1, 3, 4)

Geometrik olarak zor ve dağınık durumlarda da yanlış noktalar arası farkı tahmin etmiştir. (Örnek 2, 5)




4.3 - Problem C

Problem C için farklı eğitim kümesi oranları ile sonuçlar aşağıdaki gibidir:

Eğitim Kümesi Oranı	Eğitim Veri Adeti	Epoch	Accuracy
%25	900	27	0.412
%50	1800	41	0.792
%100	3600	73	0.951


Bu problemde veri boyutu doğruluğu çok fazla etkilemiştir. %100 eğitim kümesi oranı için doğruluk %95'e kadar çıkmıştır. Modelin Problem A ve B'ye göre daha iyi bir performans gösterdiği söylenebilir.


Problem C: Nokta sayısı (1-10)
Veri Boyutunun Etkisi




Eğitim eğrileri incelendiğinde %25 ve %50 eğitim kümesi oranları için overfitting gözlemlenmiştir. Loss düşmesine rağmen accuracy takılmıştır.1

Problem C: Nokta sayısı (1-10) — Eğitim Süreçleri





Problem C için en kötü sonuçlar incelendiğinde confusion matrix'e benzer şekilde model 7-9 aralığı için kötü tahminler yapmıştır. Model yakın sınıflar arasında karmaşıklık yaşamıştır. Nokta sayısı arttıkça noktalar birbirine yaklaşmış, bu sebeple sayım zorlaşmıştır.





4.4 - Problem D

Problem D için farklı eğitim kümesi oranları ile sonuçlar aşağıdaki gibidir:


Eğitim Kümesi Oranı	Eğitim Veri Adeti	Epoch	Accuracy
%25	360	32	0.567
%50	720	22	0.493
%100	1440	38	0.512

Model en kötü performansı bu problemde göstermiştir ve başarısız olmuştur. Doğruluk oranı %50'de kalmıştır (rastgele) ve eğitim verisi artmasına rağmen model bu problemi öğrenememiştir.

CNN mimarisi bu problemi çözememiştir çünkü tek / çift ayrımı yapabilmek için genel sayma yapılması gerekir. CNN ise yerel özellik çıkarır ve bu özellikler herhangi bir ipucu sağlamaz. Bu sebeple model matrisler arasında ayırım yapamaz.



Eğitim eğrilerine bakıldığında modelin eğitim verisini ezberleyebildiği ancak test setinde bunları genelleylemediği gözlemlenmiştir. Doğruluk %50 civarında rastgele olarak değişmektedir.



4.5 - Problem E


Problem E için farklı eğitim kümesi oranları ile sonuçlar aşağıdaki gibidir:

Eğitim Kümesi Oranı	Eğitim Veri Adeti	Epoch	MAE	RMSE	R ²
%25	1728	36	3.796	5.881	0.820
%50	3456	59	3.523	5.786	0.826
%100	6912	56	3.180	5.361	0.850

Köşe mesafesi problemi için model ilk üç probleme göre daha kötü performans göstermiştir. Bunun sebebi Problem E'nin aynı zamanda Problem D'yi de içermesidir.


Model mesafe kavramını iyi bir şekilde öğrenebilmesine rağmen tek / çift ayrımını yapamadığı için yanlış köşeye göre mesafe tahmininde bulunmuştur.

Eğitim verisi arttırıldığında tahmin doğruluğu artmasına rağmen bu yetersizlikten dolayı artış sınırlı kalmıştır.




Değer aralıkları için MAE'e bakıldığında çok net bir şekilde asimetri gözlemlenmiştir. Bunun sebebi modelin tek / çift ayrımından dolayı yanlış köşeyi seçmesidir.


Düşük değerlerde parity aşırı fazla etkili olurken yüksek değerlerde model her iki köşeye de yakınlığı birlikte öğrenmiş bu sebeple de daha doğru tahminde bulunabilmiştir. Bu yüksek değerlerde işe yararken düşük değerlerde işe yaramamıştır.



Hata dağılımına bakıldığında da benzer sonuçlar gözlemlenmiştir.



Problem E için kötü sonuçlara baktığımızda modelin mesafe hesabını yaklaşık olarak doğru yapabildiği fakat yanlış köşeye göre hesap yaptığı için çok uzak değerler tahmin ettiği görülmektedir.



5 - Sonuç

25x25 binary matris girişi üzerinden beş problem için CNN tabanlı yapay sinir ağları eğitilmiş ve performansları değerlendirilmiştir.

Tablo halinde toplu sonuçlar:

Problem	Tip	Metrik	%25	%50	%100
A - Min Manhattan Mesafesi	Regresyon	MAE	2.360	1.752	1.414
B - Max Manhattan Mesafesi	Regresyon	MAE	2.431	1.890	1.648
C - Nokta Sayısı	Sınıflandırma	Accuracy	0.412	0.762	0.951
D - Tek / Çift	Sınıflandırma	Accuracy	0.567	0.493	0.512
E - Köşe Mesafesi	Regresyon	MAE	3.796	3.523	3.180

Sonuçlar, CNN mimarisinin yerel örüntülere dayanan problemlerde (A, B, C) başarılı olduğunu ancak global yapıda olan problemlerde (D) yetersiz kaldığını göstermiştir.

Problem A ve B’de model, nokta çiftleri arasındaki mesafe ilişkilerini öğrenebilmiştir.

Problem B, yalnızca en uçtaki noktaların tespitini gerektirdiğinden Problem A’ya kıyasla daha dengeli sonuçlar üretmiştir.

Problem C’de %95 doğruluk ile en başarılı sonuç elde edilmiştir.

Problem D ise projenin en önemli negatif bulgusudur. Tek / çift belirleme global bir problem olduğundan ve hiçbir yerel özellik bu bilgiyi taşımadığından CNN mimarisi ile çözülememiştir. Bu başarısızlık mimari sınırlamasından kaynaklanmakta olup daha fazla veri veya daha derin ağ ile aşılamamaktadır.

Problem E, D’nin sınırlamaları sebebiyle kötü performans göstermiştir. Model mesafe kavramını öğrenebilmesine rağmen, doğru köşeyi seçebilmek için tek / çift bilgisine ihtiyaç duyulduğundan dolayı düşük mesafe değerlerinde ciddi hatalar yaşanmıştır.

Tüm problemlerde eğitim verisi miktarının artırılması, öğrenilebilir problemlerde (A, B, C, E) tutarlı iyileşme sağlarken, yapısal olarak çözülemeyen D probleminde hiçbir etki gösterememiştir. Bu durum, model başarısının yalnızca veri miktarına değil, problemin yapay sinir ağlarına uygunluğuna da bağlı olduğunu ortaya koymaktadır.